Contents

数学基础 **3**
贝叶斯公式 4
常见分布 4
伯努利分布 4
二项分布 4
多项分布 4
参数估计 5
极大似然估计 (MLE) 5
最大后验概率估计 (MAP) 5

生成式分类器 **5**
分类目标 5
最小化误分类率 6
最小化期望风险 6
类先验概率 6
类条件概率 7
高斯分布 7
高斯判别分析 (GDA) 7
线性判别分析 (LDA) 8

判别式分类器 **8**
线性多分类判别 8
One vs Rest 8
One vs One 8
线性分类器 9
Fisher 线性判别分析 9
感知器 9
多项式判别 10
决策树 11
ID3 11
C4.5 11
CART 11

线性回归 **11**
极大似然估计 12
损失函数 12
最大后验估计 13

梯度下降法 14
解析解 14

Logistic 回归 **15**
似然函数 16
梯度下降法 16
正则化 17

SVM **17**
间隔 17
对偶问题 18
带松弛变量的 SVM 20
核函数 20

特征工程 **21**
数据预处理 21
数值型/连续型特征 21
类别型/离散型特征 21

降维 **21**
PCA 21
SVD 23
核化 PCA (KPCA) 23
自编码器 (AutoEncoder) 23
MDS 24
局部结构保持的降维算法 24
LLE 24
T-SNE 24
UMAP 24

统计学习基础 **24**
过拟合与欠拟合 24
偏差与方差 25
模型复杂度 25

聚类 **26**
K-Means 26
肘部法 26
假设检验法 26
K-Means++ 27

高斯混合模型 27
层次聚类 27
DBSCAN 27
评价指标 28
Jaccard 系数 28
Rand 指数 28
轮廓系数 28

集成学习 **28**
Bagging 28
随机森林 29
极度随机树 29
Bootstrap 29
Boosting 29
AdaBoost 29
Gradient Boosting 31

数学基础

- 训练集 $D = \{(x_1, y_1), (x_2, y_2), \cdots, (x_m, y_m)\}$
- 训练样本 $x_i = \begin{bmatrix} x_{i1} \\ x_{i2} \\ \vdots \\ x_{iD} \end{bmatrix} \in \mathbb{R}^D$，文中为了合并偏置项也有使用增广向量的形式 $x_i^* = \begin{bmatrix} 1 \\ x_{i1} \\ x_{i2} \\ \vdots \\ x_{iD} \end{bmatrix} \in \mathbb{R}^{D+1}$
- 样本矩阵 $X_{D\times N} = \begin{bmatrix} x_1 & x_2 & \cdots & x_N \end{bmatrix}$
- 训练集标签/预测值 y_i
- - 二分类 $y_i \in \{0, 1\}$ 或 $\{-1, 1\}$
- - 多分类 $y_i \in \{1, 2, \cdots, K\}$
- - 回归 $y_i \in \mathbb{R}$
- 模型 $f(x; \theta)$，有时也记作 $f_\theta(x)$，其中 θ 为模型参数，下文也用 ω 替代
- 损失函数 $L(y, f(x; \theta))$，也记作 $L(y, f_\theta(x))$

贝叶斯公式

$$
\begin{aligned}
p(Y=c|X=x) &= \frac{p(X=x|Y=c)p(Y=c)}{p(X=x)} \\
&= \frac{p(X=x|Y=c)p(Y=c)}{\sum_{i=1}^{K} p(X=x|Y=i)p(Y=i)}
\end{aligned}
$$

常见分布

伯努利分布

$$
\begin{aligned}
p(x) &= p^x(1-p)^{1-x} \\
\mathbb{E}[x] &= p \\
\mathbb{D}[x] &= p(1-p)
\end{aligned}
$$

二项分布

$$
\begin{aligned}
p(x) &= \binom{N}{x} p^x(1-p)^{n-x} \\
\mathbb{E}[x] &= Np \\
\mathbb{D}[x] &= Np(1-p)
\end{aligned}
$$

多项分布

记 x_i 表示第 i 类样本的数量，p_i 表示第 i 类样本的概率，N 表示样本总数，K 表示类别总数，有

$$
p(x_1, x_2, \cdots, x_K) = \frac{N!}{x_1! x_2! \cdots x_K!} p_1^{x_1} p_2^{x_2} \cdots p_K^{x_K}
$$

参数估计

极大似然估计 (MLE)

$$
\begin{aligned}
\mathcal{L}(\theta) &= \prod_{i=1}^{m} p(x_i;\theta) \\
\hat{\theta} &= \arg\max_{\theta} \mathcal{L}(\theta) \\
\log \mathcal{L}(\theta) &= \sum_{i=1}^{m} \log p(x_i;\theta) \\
\hat{\theta} &= \arg\max_{\theta} \log \mathcal{L}(\theta) \\
\frac{\partial \log \mathcal{L}(\theta)}{\partial \theta} &= \sum_{i=1}^{m} \frac{\partial \log p(x_i;\theta)}{\partial \theta} \\
&= \sum_{i=1}^{m} \frac{1}{p(x_i;\theta)} \frac{\partial p(x_i;\theta)}{\partial \theta} = 0
\end{aligned}
$$

最大后验概率估计 (MAP)

$$
\begin{aligned}
\hat{\theta} &= \arg\max_{\theta} p(\theta|D) \\
&= \arg\max_{\theta} \frac{p(D|\theta)p(\theta)}{p(D)} \\
&= \arg\max_{\theta} p(D|\theta)p(\theta) \\
&= \arg\max_{\theta} \mathcal{L}(\theta)p(\theta) \\
&= \arg\max_{\theta} [\log \mathcal{L}(\theta) + \log p(\theta)] \\
\frac{\partial [\log \mathcal{L}(\theta) + \log p(\theta)]}{\partial \theta} &= \frac{\partial \log \mathcal{L}(\theta)}{\partial \theta} + \frac{\partial \log p(\theta)}{\partial \theta} \\
&= \sum_{i=1}^{m} \frac{1}{p(x_i;\theta)} \frac{\partial p(x_i;\theta)}{\partial \theta} + \frac{1}{p(\theta)} \frac{\partial p(\theta)}{\partial \theta} = 0
\end{aligned}
$$

生成式分类器

分类目标

- 最小化误分类率，等价于最大后验概率
- 最小化期望风险，实际一般寻找最小条件风险

最小化误分类率

$$
\begin{aligned}
p(error) &= \int p(x)p(error|x)dx \\
&= \int [1-p(Y=c|x)]p(x)dx \\
p(error|x) &= 1-\underbrace{p(Y=c|x)}_{\text{后验概率}} \\
&= 1-\frac{p(x|Y=c)p(Y=c)}{p(x)} \\
\hat{y} &= \arg\max_c p(Y=c|x) \\
&= \arg\max_c p(x|Y=c)\,\underbrace{p(Y=c)}_{\text{先验概率}}
\end{aligned}
$$

最小化期望风险

记将 i 类样本预测为 j 类样本的惩罚为 L_{ij}，则将样本预测为类别 c 的条件风险为

$$
\begin{aligned}
R(c|x) &= \sum_{i=1}^{K} L_{ic}p(Y=i|x) \\
\hat{y} &= \arg\min_c R(c|x)
\end{aligned}
$$

期望风险为

$$
\begin{aligned}
R_{exp} &= \int R(c|x)p(x)dx \\
&= \int [\sum_{i=1}^{K} L_{ic}p(Y=i|x)]p(x)dx
\end{aligned}
$$

当损失函数 L_{ij} 为 0-1 损失函数时

$$
\sum_{i=1}^{K} L_{ic}p(Y=i|x) = 1-p(Y=c|x) = p(error|x)
$$

此时期望风险等价于最小化误分类率

类先验概率

- 二分类，$y \sim Bernoulli(\phi)$

- 多分类，$y \sim Multinomial(\phi_1, \phi_2, \cdots, \phi_K)$

MLE 估计的先验概率等价于样本中各类别的比例

类条件概率

- 离散型特征，满足特征独立性假设，$p(x|Y=c) = \prod_{i=1}^{D} p(x_i|Y=c)$
- 连续型特征，特征服从高斯分布，$p(x_{i,j}|Y=c) = \frac{1}{\sqrt{2\pi}\sigma_{c,j}} e^{-\frac{(x_{i,j}-\mu_{c,j})^2}{2\sigma_{c,j}^2}}$

高斯分布

单变量高斯分布

$$
\begin{aligned}
p(x) &= \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}} \\
\mathbb{E}[x] &= \mu \\
\mathbb{D}[x] &= \sigma^2
\end{aligned}
$$

多变量高斯分布

$$
\begin{aligned}
p(x) &= \frac{1}{(2\pi)^{\frac{D}{2}} |\Sigma|^{\frac{1}{2}}} e^{-\frac{1}{2}(x-\mu)^T \Sigma^{-1} (x-\mu)} \\
\mathbb{E}[x] &= \mu \\
\mathbb{D}[x] &= \Sigma = \mathbb{E}[(x-\mu)(x-\mu)^T]
\end{aligned}
$$

高斯判别分析 (GDA)

$$
\begin{aligned}
p(Y=c|X=x) = \frac{p(X=x|Y=c)p(Y=c)}{p(X=x)} &\propto p(X=x|Y=c)p(Y=c) \\
f_c(x) &= \log p(X=x|Y=c)p(Y=c) \\
&= \log p(Y=c) + \log p(X=x|Y=c) \\
&= \log p(Y=c) + \log \frac{1}{(2\pi)^{\frac{D}{2}} |\Sigma_c|^{\frac{1}{2}}} e^{-\frac{1}{2}(x-\mu_c)^T \Sigma_c^{-1} (x-\mu_c)} \\
&= \log p(Y=c) - \frac{1}{2} \log |\Sigma_c| - \frac{1}{2}(x-\mu_c)^T \Sigma_c^{-1} (x-\mu_c) - \underbrace{\frac{D}{2} \log 2\pi}_{\text{常数}}
\end{aligned}
$$

线性判别分析 (LDA)

假定两类样本的协方差矩阵相同，即 $\Sigma_1 = \Sigma_2 = \Sigma$，则有

$$
\begin{aligned}
d_1(x) &= \log \frac{N_1}{N} - \frac{1}{2}\log|\Sigma| - \frac{1}{2}(x-\mu_1)^T\Sigma^{-1}(x-\mu_1) \\
d_2(x) &= \log \frac{N_2}{N} - \frac{1}{2}\log|\Sigma| - \frac{1}{2}(x-\mu_2)^T\Sigma^{-1}(x-\mu_2) \\
d_1(x) - d_2(x) &= \log \frac{N_1}{N_2} - \frac{1}{2}(x-\mu_1)^T\Sigma^{-1}(x-\mu_1) + \frac{1}{2}(x-\mu_2)^T\Sigma^{-1}(x-\mu_2) \\
&= \log \frac{N_1}{N_2} + \mu_1^T\Sigma^{-1}x - \mu_2^T\Sigma^{-1}x - \frac{1}{2}\mu_1^T\Sigma^{-1}\mu_1 + \frac{1}{2}\mu_2^T\Sigma^{-1}\mu_2 \\
&= (\mu_1-\mu_2)^T\Sigma^{-1}x + \underbrace{\log \frac{N_1}{N_2} - \frac{1}{2}\mu_1^T\Sigma^{-1}\mu_1 + \frac{1}{2}\mu_2^T\Sigma^{-1}\mu_2}_{\text{常数}}
\end{aligned}
$$

可得线性判别界面

$$
(\mu_1-\mu_2)^T\Sigma^{-1}x = \frac{1}{2}\mu_1^T\Sigma^{-1}\mu_1 - \frac{1}{2}\mu_2^T\Sigma^{-1}\mu_2 - \log\frac{N_1}{N_2}
$$

判别式分类器

线性多分类判别

One vs Rest

当且仅当只有一个类别为正时，分类成功

$$
f_c(x) \begin{cases} > 0 & y = c \\ \leq 0 & y \neq c \end{cases}
$$

One vs One

判别函数多每两个类别构造一个判别函数，当且仅当对类别 k 有 $\forall c \neq k, f_{k,c}(x) > 0$ 时，分类成功

$$
f_{c_1,c_2}(x) = -f_{c_2,c_1}(x) \begin{cases} > 0 & y = c_1 \\ < 0 & y = c_2 \end{cases}
$$

一对一分类也可参考一对其他分类的思想，将 $f_{c_1,c_2}(x)$ 看作类别 f_{c_1} 与 f_{c_2} 的差，此时上述条件等价于 $\arg\max_c f_c(x)$

线性分类器

Fisher 线性判别分析

$$
\begin{aligned}
S_B &= (\mu_1-\mu_2)(\mu_1-\mu_2)^T \\
S_W &= \sum_{c=1}^{K}\sum_{i=1}^{N_c}\mathbb{I}(y_i=c)(x_i-\mu_c)(x_i-\mu_c)^T = \sum_{i=1}^{N}(x_i-\mu_{y_i})(x_i-\mu_{y_i})^T
\end{aligned}
$$

构造线性变换 $z=w^Tx$，使得类间散度尽量大，类内散度尽量小

$$
\max_w J(w) = \frac{w^TS_Bw}{w^TS_Ww}
$$

解 Rayleigh 商问题，有

$$
\begin{aligned}
S_Bw &= \lambda S_Ww \\
\lambda w &= S_W^{-1}S_Bw \\
&= S_W^{-1}(\mu_1-\mu_2)\underbrace{(\mu_1-\mu_2)^T}_{1\times D}w_{D\times 1} \\
w &\propto S_W^{-1}(\mu_1-\mu_2)
\end{aligned}
$$

判别面为投影后的中点 $\frac{1}{2}(w^T\mu_1+w^T\mu_2)$

$$
w^Tx = \frac{w^T}{2}(\mu_1+\mu_2)
$$

感知器

以二分类为例，$y\in\{-1,1\}$，判别函数为

$$
\hat{y} = \mathbf{sgn}(w^Tx+b) = \begin{cases} 1 & w^Tx+b>0 \\ -1 & w^Tx+b\le 0 \end{cases}
$$

损失函数为

$$\min_{w,b}\sum_{i=1}^{N}-y_i(w^Tx_i+b)$$

梯度下降法更新参数

$$\begin{aligned}
w_{t+1} &\leftarrow w_t-\eta\frac{\partial L}{\partial w}\\
b_{t+1} &\leftarrow b_t-\eta\frac{\partial L}{\partial b}\\
\frac{\partial L}{\partial w} &= \sum_{i=1}^{N}-y_ix_i\\
\frac{\partial L}{\partial b} &= \sum_{i=1}^{N}-y_i
\end{aligned}$$

实际操作中只根据误分类样本更新参数，即

$$\begin{aligned}
\frac{\partial L}{\partial w} &= \sum_{i=1}^{N}-y_ix_i\mathbb{I}(\hat{y}_i\neq y_i)\\
\frac{\partial L}{\partial b} &= \sum_{i=1}^{N}-y_i\mathbb{I}(\hat{y}_i\neq y_i)
\end{aligned}$$

多项式判别

n 阶多项式的总系数为 $\frac{(n+D)!}{n!D!}$

$$\begin{aligned}
f_0(x) &= w_0\\
f_1(x) &= f_0(x)+\sum_{i=1}^{D}w_ix_i\\
f_2(x) &= f_1(x)+\sum_{i=1}^{D}\sum_{j=i}^{D}w_{ij}x_ix_j\\
&\vdots\\
f_{n+1}(x) &= f_n(x)+\underbrace{\sum_{i=1}^{D}\sum_{j=i}^{D}\cdots\sum_{k=j}^{D}}_{n+1}w_{ijk\cdots}x_ix_j\cdots x_k
\end{aligned}$$

决策树

ID3

$$\text{信息增益} = H(Y) - H(Y|X)$$

分类依据为最大信息增益，等价于最小化条件熵

$$\min_{j\in\{1,2,\cdots,D\}} H(Y|X_j)$$

C4.5

$$\text{信息增益率} = \frac{H(Y) - H(Y|X)}{H(X)}$$

分裂依据为最大信息增益率

CART

$$\text{基尼指数} = \sum_{i=1}^{K} p_i(1-p_i) = 1 - \sum_{i=1}^{K} p_i^2$$

分裂依据为最小化基尼指数

线性回归

线性回归通过线性组合预测连续值

$$\hat{y} = f(x;w) = w^T x$$

这里的 w 和 x 都是增广向量，即

$$x = \begin{bmatrix} 1 \\ x_1 \\ x_2 \\ \vdots \\ x_D \end{bmatrix}, w = \begin{bmatrix} w_0 \\ w_1 \\ w_2 \\ \vdots \\ w_D \end{bmatrix} f(x;w) = w_0 + \sum_{i=1}^{D} w_i x_i$$

规定预测残差 $\epsilon = y - \hat{y}$，则有

$$
\begin{aligned}
\epsilon &\sim \mathcal{N}(0, \sigma^2) \\
y &\sim \mathcal{N}(f(x; w), \sigma^2) \\
p(y|x; w) &= \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(y-f(x;w))^2}{2\sigma^2}}
\end{aligned}
$$

通常可以通过观察残差的分布来判断模型是否合理

极大似然估计

$$
\begin{aligned}
\mathcal{L}(w) &= \prod_{i=1}^{N} p(y_i|x_i; w) \\
\log \mathcal{L}(w) &= \sum_{i=1}^{N} \log p(y_i|x_i; w) \\
&= \sum_{i=1}^{N} \log \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(y_i-f(x_i;w))^2}{2\sigma^2}} \\
&= \sum_{i=1}^{N} [\log \frac{1}{\sqrt{2\pi}\sigma} - \frac{(y_i - f(x_i; w))^2}{2\sigma^2}] \\
&= -N \log \sqrt{2\pi}\sigma - \frac{1}{2\sigma^2} \sum_{i=1}^{N} (y_i - f(x_i; w))^2
\end{aligned}
$$

- 对数似然函数取最大值时，等价于最小化均方误差 (MSE)，即 L2 损失函数
- 线性回归和 Logistic 回归的的损失函数都是负对数似然函数

损失函数

线性回归可以通过最小化均方误差 (MSE) 来求解参数

$$
\begin{aligned}
L(w) &= \sum_{i=1}^{N} (y_i - f(x_i; w))^2 \\
&= \sum_{i=1}^{N} (y_i - w^T x_i)^2 \\
&= (Y - X^T w)^T (Y - X^T w)
\end{aligned}
$$

注意这里写成 $X^T w$ 比 $w^T X$ 更容易求导。引入正则项，有

$$
\begin{aligned}
\mathcal{J}(w) &= L(w) + \lambda \mathcal{R}(w) \\
\text{L2 正则} \Rightarrow \mathcal{R}(w) &= \|w\|_2^2 = \sum_{i=1}^{D} w_i^2 \\
\text{L1 正则} \Rightarrow \mathcal{R}(w) &= \|w\|_1 = \sum_{i=1}^{D} |w_i| \\
\frac{\partial \mathcal{J}(w)}{\partial w} &= \frac{\partial L(w)}{\partial w} + \lambda \frac{\partial \mathcal{R}(w)}{\partial w} \\
&= -2XY + 2XX^T w + 2\lambda w \\
&= \underbrace{-2X(Y - X^T w)}_{\frac{\partial L(w)}{\partial w}} + \underbrace{2\lambda w}_{\frac{\partial \mathcal{R}(w)}{\partial w}}
\end{aligned}
$$

- 线性回归的正则项可以不加
- 正则项不对偏置项 w_0 进行正则化，因为偏置项不影响模型的复杂度
- 引入 L2 正则项称为岭回归 (Ridge Regression)，引入 L1 正则项称为 Lasso 回归

其他损失函数

- L1 损失函数，$L(w) = \sum_{i=1}^{N} |y_i - f(x_i; w)|$
- Huber 损失函数

$$
L(w) = \sum_{i=1}^{N} \begin{cases} \frac{1}{2}(y_i - f(x_i; w))^2 & |y_i - f(x_i; w)| \le \delta \\ \delta |y_i - f(x_i; w)| - \frac{1}{2}\delta^2 & |y_i - f(x_i; w)| > \delta \end{cases}
$$

最大后验估计

引入先验概率 $p(w)$，有

$$
\begin{aligned}
\hat{w} &= \arg\max_w p(w|D) \\
&= \arg\max_w \frac{p(D|w)p(w)}{p(D)} \\
&= \arg\max_w p(D|w)p(w) \\
&= \arg\max_w \log p(D|w) + \log p(w) \\
p(D|w) &= \prod_{i=1}^{N} p(y_i|x_i;w) \sim \mathcal{N}(f(x_i;w),\sigma^2) \\
p(w) &= \prod_{i=1}^{D} p(w_i) \sim \mathcal{N}(0,\sigma_w^2) \\
\hat{w} &= \arg\max_w [\sum_{i=1}^{N} \log p(y_i|x_i;w) + \sum_{i=1}^{D} \log p(w_i)] \\
&= \arg\max_w [\sum_{i=1}^{N} \log \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(y_i-f(x_i;w))^2}{2\sigma^2}} + \sum_{i=1}^{D} \log \frac{1}{\sqrt{2\pi}\sigma_w} e^{-\frac{w_i^2}{2\sigma_w^2}}] \\
&= \arg\max_w [-N\log\sqrt{2\pi}\sigma - \frac{1}{2\sigma^2}\sum_{i=1}^{N}(y_i - f(x_i;w))^2 - D\log\sqrt{2\pi}\sigma_w - \frac{1}{2\sigma_w^2}\sum_{i=1}^{D} w_i^2] \\
&= \arg\min_w [\frac{1}{2\sigma^2}\sum_{i=1}^{N}(y_i - f(x_i;w))^2 + \frac{1}{2\sigma_w^2}\sum_{i=1}^{D} w_i^2]
\end{aligned}
$$

最后后验估计等价于参数满足高斯分布的带 L2 正则项的 L2 损失函数

梯度下降法

梯度下降法更新参数

$$
w_{t+1} \leftarrow w_t - \eta \frac{\partial \mathcal{J}}{\partial w}
$$

解析解

令 $\frac{\partial L(w)}{\partial w} = 0$，有

$$
\begin{aligned}
\frac{\partial L(w)}{\partial w} &= -2X(Y - X^T w) = 0 \\
XX^T w &= XY \\
w &= (XX^T)^{-1} XY
\end{aligned}
$$

这里涉及到对矩阵 XX^T 求逆，可以通过 SVD 分解来求解

$$
\begin{aligned}
X &= U\Sigma V^T \\
XX^T &= U\Sigma V^T V \Sigma U^T = U\Sigma^2 U^T \\
(XX^T)^{-1} &= U\Sigma^{-2} U^T \\
w &= U\Sigma^{-2} U^T U \Sigma V^T Y \\
&= U\Sigma^{-1} V^T Y
\end{aligned}
$$

Logistic 回归

Logistic 回归是一种分类算法

$$
x = \begin{bmatrix} 1 \\ x_1 \\ x_2 \\ \vdots \\ x_D \end{bmatrix}
$$

$$
w^T x = \sum_{i=0}^{D} w_i x_i = w_0 + \sum_{i=1}^{D} w_i x_i
$$

以二分类为例，$y \in \{0, 1\}$，判断样本为正的概率为

$$
p(y = 1|x) = \sigma(w^T x) = \frac{1}{1 + e^{-w^T x}} = \frac{e^{w^T x}}{1 + e^{w^T x}} \in (0, 1)
$$

判断样本为负的概率为

$$
p(y = 0|x) = 1 - p(y = 1|x) = \frac{1}{1 + e^{w^T x}} \in (0, 1)
$$

判别函数为

$$
\begin{aligned}
\log \frac{p(y=1|x)}{p(y=0|x)} &= \log \frac{\frac{e^{w^T x}}{1+e^{w^T x}}}{\frac{1}{1+e^{w^T x}}} \\
&= w^T x \\
p(y=1|x) > p(y=0|x) &\Leftrightarrow w^T x > 0
\end{aligned}
$$

记判断样本为正的函数为 $\mu(x)$，则有

$$
p(y|x) = \mu(x)^y (1-\mu(x))^{1-y}
$$

似然函数

对应的对数似然函数为

$$
\begin{aligned}
\mathcal{L}(w) &= \prod_{i=1}^{N} p(y_i|x_i) \\
\log \mathcal{L}(w) &= \sum_{i=1}^{N} \log p(y_i|x_i) \\
&= \sum_{i=1}^{N} [y_i \log \mu(x_i) + (1-y_i) \log(1-\mu(x_i))] \\
&= \sum_{i=1}^{N} [y_i \log \frac{\mu(x_i)}{1-\mu(x_i)} + \log(1-\mu(x_i))] \\
&= \sum_{i=1}^{N} [y_i (w^T x_i) - \log(1+e^{w^T x_i})]
\end{aligned}
$$

Logistic 回归的损失函数与负对数似然函数等价，即交叉熵损失函数

$$
\begin{aligned}
L(w) &= -\log \mathcal{L}(w) \\
&= \sum_{i=1}^{N} [\log(1+e^{w^T x_i}) - y_i w^T x_i]
\end{aligned}
$$

梯度下降法

梯度下降法更新参数

$$
\begin{aligned}
w_{t+1} &\leftarrow w_t - \eta \frac{\partial L}{\partial w} \\
\frac{\partial L}{\partial w} &= \sum_{i=1}^{N} x_i(\mu(x_i) - y_i) = X(\mu - Y)
\end{aligned}
$$

这里的 μ 和 Y 都是 $N \times 1$ 的向量，$\mu_i = \mu(x_i)$，$Y_i = y_i$

正则化

在损失函数中加入正则项，有

$$
\begin{aligned}
\mathcal{J}(w) &= L(w) + \lambda \mathcal{R}(w) \\
\text{L2 正则} &\Rightarrow \mathcal{R}(w) = \|w\|_2^2 = w^T w \\
\text{L1 正则} &\Rightarrow \mathcal{R}(w) = \|w\|_1 = \sum_{i=0}^{D} |w_i| \\
\frac{\partial \mathcal{J}(w)}{\partial w} &= \frac{\partial L(w)}{\partial w} + \lambda \frac{\partial \mathcal{R}(w)}{\partial w} \\
&= X(\mu - Y) + 2\lambda w
\end{aligned}
$$

线性回归可以不加正则项，Logistic 回归一般都要加正则项，否则会过拟合，即 $|w| \to \infty$；在 sklearn 中，Logistic 回归的正则参数为 $C = \frac{1}{\lambda}$，C 越大，正则化越弱

$$
\mathcal{J}(w) = CL(w) + \|w\|_2^2
$$

SVM

SVM 属于线性分类器，通过最大化分类间隔来求解参数

$$
f(x; w, b) = w^T x + b \hat{y} = \mathbf{sgn}(f(x; w, b)) = \begin{cases} 1 & w^T x + b > 0 \\ -1 & w^T x + b < 0 \end{cases}
$$

间隔

判别面方程为

$$
w^T x + b = 0
$$

对于任意样本 x，到判别面的距离为

$$\frac{|w^T x + b|}{\|w\|_2}$$

假定最小距离 $\min\limits_{x \in D} \frac{|w^T x+b|}{\|w\|_2} = 1$，那么正负样本的距离之和/判别器的间隔为 $\frac{2}{\|w\|_2}$，SVM 的目标是最大化间隔

$$\arg\max_{w,b} \frac{2}{\|w\|_2}$$
$$\text{s.t. } y_i(w^T x_i + b) \geq 1$$
$$\text{等价于} \arg\min_{w,b} \frac{1}{2}\|w\|_2^2$$

最大化间隔等价于最小化模型复杂度；SVM 是从几何角度来解决分类问题的，而不是从概率角度来解决分类问题的，与 Logistic 回归不同

对偶问题

引入拉格朗日乘子 $\alpha_i \geq 0$，有

$$
\begin{aligned}
\mathcal{L}(w,b,\alpha) &= \frac{1}{2}\|w\|_2^2 - \sum_{i=1}^{N}\alpha_i[y_i(w^Tx_i+b)-1] \\
\frac{\partial\mathcal{L}(w,b,\alpha)}{\partial w} &= w - \sum_{i=1}^{N}\alpha_i y_i x_i = 0 \\
w &= \sum_{i=1}^{N}\alpha_i y_i x_i \\
\frac{\partial\mathcal{L}(w,b,\alpha)}{\partial b} &= -\sum_{i=1}^{N}\alpha_i y_i = 0 \\
0 &= \sum_{i=1}^{N}\alpha_i y_i \\
\mathcal{L}(w,b,\alpha) &= \frac{1}{2}w^Tw - \sum_{i=1}^{N}\alpha_i[y_i(w^Tx_i+b)-1] \\
&= \frac{1}{2}w^Tw - \sum_{i=1}^{N}\alpha_i y_i w^Tx_i - \sum_{i=1}^{N}\alpha_i y_i b + \sum_{i=1}^{N}\alpha_i \\
\text{代入} &= \frac{1}{2}\sum_{i=1}^{N}\alpha_i y_i x_i^T \sum_{j=1}^{N}\alpha_j y_j x_j - \sum_{i=1}^{N}\alpha_i y_i \sum_{j=1}^{N}\alpha_j y_j x_j^T x_i - \sum_{i=1}^{N}\alpha_i y_i b + \sum_{i=1}^{N}\alpha_i \\
&= \frac{1}{2}\sum_{i=1}^{N}\sum_{j=1}^{N}\alpha_i\alpha_j y_i y_j x_i^T x_j - \sum_{i=1}^{N}\sum_{j=1}^{N}\alpha_i\alpha_j y_i y_j x_i^T x_j - b\sum_{i=1}^{N}\alpha_i y_i + \sum_{i=1}^{N}\alpha_i \\
&= \sum_{i=1}^{N}\alpha_i - \frac{1}{2}\sum_{i=1}^{N}\sum_{j=1}^{N}\alpha_i\alpha_j y_i y_j x_i^T x_j
\end{aligned}
$$

因此原问题等价于

$$
\begin{aligned}
&\arg\max_{w,b}\sum_{i=1}^{N}\alpha_i - \frac{1}{2}\sum_{i=1}^{N}\sum_{j=1}^{N}\alpha_i\alpha_j y_i y_j x_i^T x_j \\
&\text{s.t. } \sum_{i=1}^{N}\alpha_i y_i = 0 \text{ and } \forall i, \alpha_i \geq 0
\end{aligned}
$$

这里的 α_i 称为拉格朗日乘子，原问题称为原始问题，上式称为对偶问题，对偶问题的解为 α_i，原始问题的解为 $w = \sum_{i=1}^{N}\alpha_i y_i x_i$，$b$ 的解可以通过 KKT 条件求解；对应的 KKT 条件为

$$
\begin{aligned}
\alpha_i[y_i(w^Tx_i+b)-1] &= 0 \\
y_i(w^Tx_i+b)-1 &\geq 0 \\
\alpha_i &\geq 0
\end{aligned}
$$

- $\alpha_i = 0$，对应的样本不参与计算，即不是支持向量
- $\alpha_i > 0$，对应的样本参与计算，即是支持向量，此时 $y_i(w^T x_i + b) = 1$，即距离判别面最近的样本

带松弛变量的 SVM

引入松弛变量 $\xi_i \geq 0$，有

$$\begin{aligned}&\arg\min_{w,b,\xi} \frac{1}{2}\|w\|_2^2 + C\sum_{i=1}^{N}\xi_i \\ &\text{s.t. } y_i(w^T x_i + b) \geq 1 - \xi_i \text{ and } \forall i, \xi_i \geq 0\end{aligned}$$

这里的 C 称为惩罚参数，C 越大，惩罚越大，模型对异常值越敏感，越趋向于 Hard Margin SVM，同时训练误差也越小，模型的间隔越小，模型越复杂，越趋向于 Overfitting；引入合页损失，有

$$\begin{aligned}&\arg\min_{w,b} \frac{1}{2}\|w\|_2^2 + C\sum_{i=1}^{N}\max(0, 1 - y_i(w^T x_i + b)) \\ &\text{s.t. } \forall i, \xi_i \geq 0\end{aligned}$$

核函数

引入基函数 $\phi(x)$，有

$$\begin{aligned}f(x) &= w^T\phi(x) + b \\ &= \sum_{i=1}^{N}\alpha_i y_i \phi(x_i)^T\phi(x) + b \\ &= \sum_{i=1}^{N}\alpha_i y_i K(x_i, x) + b\end{aligned}$$

上式说明实现核技巧有两种方法：一种是显式地定义基函数 $\phi(x)$，即将原始特征映射到高维空间，然后在高维空间中求解；另一种是隐式地定义基函数，即定义核函数 $K(x_i, x)$，然后在原始空间中求解；常用的核函数有

- 线性核函数，$K(x_i, x) = x_i^T x$
- 多项式核函数，$K(x_i, x) = (x_i^T x)^d$
- 高斯核函数，$K(x_i, x) = e^{-\frac{\|x_i - x\|_2^2}{2\sigma^2}}$
- 拉普拉斯核函数，$K(x_i, x) = e^{-\frac{\|x_i - x\|_1}{\sigma}}$
- Sigmod 核函数，$K(x_i, x) = \tanh(\beta x_i^T x + \theta)$

高斯核的参数 σ 称为带宽，用 $\gamma = \frac{1}{2\sigma^2}$ 表示其倒数，γ 越大，高斯核越窄，模型越复杂，每个支持向量影响的范围越小，相应的支持向量的数量也更多，模型越趋向于 Overfitting

特征工程

数据预处理

数值型/连续型特征

- 归一化/标准化
- 对数变换
- 区间划分
- 二值化
- 多项式扩展

类别型/离散型特征

- 标签编码/Lable Encoding：将类别映射为对应序号 $y \in \{1, 2, \cdots, K\}$
- 独热编码/One-hot Encoding：将类别映射为稀疏向量 $y_i = \begin{bmatrix} 0 & 0 & \cdots & 1 & \cdots & 0 \end{bmatrix}^T$
- 计数编码：用条件概率对特征进行编码 $p(Y = c|X = x) = \frac{p(X=x,Y=c)}{p(X=x)}$
-
  - 可能发生信息泄露，导致模型过拟合；可以通过增加噪声来解决
-
  - 一般用于数据量较大的场景
- 哈希编码：将类别映射为哈希值，可以减少存储空间
- 嵌入式编码：Word2Vec、GloVe、FastText 等学习得来的向量

低基数类别型特征适用于独热编码，高基数类别型特征适用于哈希编码或计数编码；类别型特征的编码方式可以作为模型的超参数进行调优

降维

PCA

PCA 是一种无监督的降维算法，通过线性变换将原始特征映射到低维空间，对于原始数据集 $X_{D\times N}$，构造线性变换 $W_{D\times d}$，且 W 是正交矩阵，则有

$$
\begin{aligned}
W^TW &= I \\
\|W_i\|_2 &= 1 \\
Z &= W^TX \\
X &= WZ
\end{aligned}
$$

PCA 的目标是最小化重构误差

$$
\begin{aligned}
&\arg\min_W \sum_{i=1}^N \|x_i - Wz_i\|_2^2 \\
=&\arg\min_W \sum_{i=1}^N (x_i - Wz_i)^T(x_i - Wz_i) \\
=&\arg\min_W \sum_{i=1}^N (x_i^Tx_i - z_i^TW^Tx_i - x_i^TWz_i + z_i^TW^TWz_i) \\
=&\arg\min_W \sum_{i=1}^N (x_i^Tx_i - 2z_i^TW^Tx_i + z_i^Tz_i) \\
=&\arg\min_W \sum_{i=1}^N (x_i^Tx_i - 2z_i^Tz_i + z_i^Tz_i) \\
=&\arg\min_W \sum_{i=1}^N (x_i^Tx_i - z_i^Tz_i) \\
=&\arg\min_W -\sum_{i=1}^N z_i^Tz_i \\
=&\arg\max_W \sum_{i=1}^N z_i^Tz_i
\end{aligned}
$$

假定样本已经中心化，可得**最小化重构误差等价于最大化投影后样本的方差**

$$
\arg\max_W \sum_{i=1}^N z_i^Tz_i = \arg\max_W tr(ZZ^T) = \arg\max_W tr(W^TXX^TW) = \arg\max_W tr(W^TSW)
$$

其中 $S = XX^T$ 为协方差矩阵，W 为协方差矩阵的特征向量，PCA 的解为协方差矩阵的 d 个最大特征值对应的特征向量，对应的步骤如下

1. 对原始数据集进行中心化处理，即 $X \leftarrow X - \frac{1}{N}\sum_{i=1}^N x_i$
2. 计算协方差矩阵 $S = XX^T$
3. 对 S 做特征值分解
4. 取 d 个最大特征值对应的特征向量 $w_1, w_2, \cdots, w_d$

5. 构造变换矩阵 $W = [w_1, w_2, \cdots, w_d]$

SVD

当对协方差矩阵做特征值分解时，可以用 SVD 分解来求解

$$
\begin{aligned}
X &= U\Sigma V^T \\
XX^T &= U\Sigma V^T V\Sigma U^T = U\Sigma^2 U^T
\end{aligned}
$$

值得一提的是：奇异值分解的对角矩阵的对角线上的元素是奇异值，奇异值的平方是协方差矩阵的特征值

核化 PCA (KPCA)

KPCA 是一种非线性的降维算法，通过核技巧将原始特征映射到高维空间，然后在高维空间中求解 PCA，对于原始数据集 $X_{D\times N}$，对应的映射函数为 $\phi(x)$，则有 $Z = W^T\phi(X)$，$\phi(X) = WZ$

引入核函数 $K(x_i, x_j) = \phi(x_i)^T\phi(x_j)$，KPCA 的步骤如下

1. 计算核矩阵 K，$K_{ij} = K(x_i, x_j)$
2. 对核矩阵中心化得到 $\bar{K}$
3. 对 $\bar{K}$ 做特征值分解
4. 取 d 个最大特征值对应的特征向量 $\alpha_1, \alpha_2, \cdots, \alpha_d$
5. 降维后的样本为 $z = A^T \begin{bmatrix} K(x, x_1) \\ K(x, x_2) \\ \vdots \\ K(x, x_N) \end{bmatrix} = \begin{bmatrix} \alpha_1^T \\ \alpha_2^T \\ \vdots \\ \alpha_d^T \end{bmatrix} \begin{bmatrix} K(x, x_1) \\ K(x, x_2) \\ \vdots \\ K(x, x_N) \end{bmatrix} = \begin{bmatrix} \sum_{i=1}^N \alpha_{1i} K(x, x_1) \\ \sum_{i=1}^N \alpha_{2i} K(x, x_2) \\ \vdots \\ \sum_{i=1}^N \alpha_{di} K(x, x_N) \end{bmatrix}$

自编码器 (AutoEncoder)

用一个编码器网络 f 代替降维函数 $Z = W^T X$，用一个解码器网络 g 代替重构函数 $X = WZ$，则有

$$
\mathcal{J}(W) = \sum_{i=1}^N \|x_i - \hat{x}_i\|_2^2 + \lambda\mathcal{R}(W) = \sum_{i=1}^N \|x_i - g(f(x_i))\|_2^2 + \lambda\mathcal{R}(f)
$$

MDS

MDS 是一种无监督的降维算法，通过保持样本间的距离关系来求解参数

1. 计算样本间的距离矩阵 D，$d_{ij} = \|x_i - x_j\|_2$
2. 计算阵 B，$b_{ij} = -\frac{1}{2}(d_{ij}^2 - \frac{1}{N}\sum_{k=1}^{N} d_{ik}^2 - \frac{1}{N}\sum_{k=1}^{N} d_{kj}^2 + \frac{1}{N^2}\sum_{k=1}^{N}\sum_{l=1}^{N} d_{kl}^2)$
3. 对 B 做特征值分解
4. 取 d 个最大特征值对应的特征向量 $w_1, w_2, \cdots, w_d$ 及其对应的特征值 $\lambda_1, \lambda_2, \cdots, \lambda_d$
5. 令 $\Lambda = diag(\lambda_1, \lambda_2, \cdots, \lambda_d)$，降维后的样本为 $z = \Lambda^{\frac{1}{2}} W^T$

MDS 和 Isomap 都是通过保持样本间的距离关系来求解参数，但是 MDS 是通过保持样本间的欧式距离来求解参数，而 Isomap 是通过保持样本间的测地距离来求解参数；两者都属于全局结构保持的降维算法

局部结构保持的降维算法

LLE

拉普拉斯特征映射 (Laplacian Eigenmaps) 是一种无监督的降维算法，通过保持样本间的局部结构来求解参数

T-SNE

将欧氏距离转换为用概率表示的相似度，然后通过 KL 散度来求解参数

UMAP

学习高维空间中的流形结构，然后在低维空间中保持流形结构

统计学习基础

过拟合与欠拟合

过拟合：模型在训练集上表现良好，在测试集上表现较差，偏差低方差高

- 降低模型复杂度
- 减少特征数量（特征选择或特征提取，即降维）
- 提高正则化水平
- Dropout

- Early Stopping
- 增加训练数据，只能降低方差，不能降低偏差

欠拟合：模型在训练集上表现较差，在测试集上表现也较差，偏差高方差低

- 增加模型复杂度，如增加多项式的阶数
- 增加特征数量
- 降低正则化水平
- 充分训练模型

偏差与方差

偏差是模型预测值与真实值之间的差异，描述了拟合结果的准确性，偏差高表示欠拟合；偏差可视作模型的训练误差

方差描述的是拟合结果的不稳定性，来源于模型对训练数据的敏感性，高方差说明模型对随机噪声也进行了拟合，对应过拟合；方差可视作训练误差与测试误差之间的差异

记 $\hat{y}$ 为模型预测值，y 为训练集上的标签，y^* 为真实值，一般认为标签与真实值之间存在噪声，即 $y = y^* + \epsilon$，其中 ϵ 为噪声，假定 $\epsilon \sim \mathcal{N}(0, \sigma^2)$，则误差可分解为

$$
\begin{aligned}
\bar{y} &= \mathbb{E}(\hat{y}) \\
\mathbb{E}[(y - y^*)^2] &= \mathbb{E}(\epsilon^2) = \mathsf{Var}(\epsilon) + \mathbb{E}^2(\epsilon) = \sigma^2 \\
\mathbb{E}[(\hat{y} - y)^2] &= \mathbb{E}[(\hat{y} - \bar{y} + \bar{y} - y)^2] \\
&= \mathbb{E}[(\hat{y} - \bar{y})^2] + \mathbb{E}[(\bar{y} - y)^2] + 2\mathbb{E}[(\hat{y} - \bar{y})(\bar{y} - y)] \\
&= \underbrace{\mathbb{E}[(\hat{y} - \bar{y})^2]}_{\text{方差}} + \mathbb{E}[(\bar{y} - y)^2] \\
&= \underbrace{\mathbb{E}[(\hat{y} - \bar{y})^2]}_{\text{方差}} + \mathbb{E}[(\bar{y} - y^* + y^* - y)^2] \\
&= \underbrace{\mathbb{E}[(\hat{y} - \bar{y})^2]}_{\text{方差}} + \mathbb{E}[(\bar{y} - y^*)^2] + \mathbb{E}[(y^* - y)^2] + 2\mathbb{E}[(\bar{y} - y^*)\,\underbrace{(y^* - y)}_{\epsilon}] \\
&= \underbrace{\mathbb{E}[(\hat{y} - \bar{y})^2]}_{\text{方差}} + (\bar{y} - y^*)^2 + \mathbb{E}[\epsilon^2] + 2(\bar{y} - y^*)\,\underbrace{\mathbb{E}[\epsilon]}_{0} \\
&= \underbrace{\mathbb{E}[(\hat{y} - \bar{y})^2]}_{\text{方差}} + \underbrace{(\bar{y} - y^*)^2}_{\text{偏差}} + \underbrace{\mathsf{Var}(\epsilon)}
\end{aligned}
$$

模型复杂度

训练误差随模型复杂度增加而减小，测试误差随模型复杂度增加而先减小后增大（过拟合）

复杂度高的模型一般具有低偏差高方差的特点，复杂度低的模型一般具有高偏差低方差的特点

聚类

K-Means

1. 随机初始化 K 个聚类中心 $\mu_1, \mu_2, \cdots, \mu_K$
2. 对每个样本 x_i，计算其与每个聚类中心的距离 $d(x_i, \mu_k)$，将其归为距离最近的聚类中心所在的类别
3. 对每个类别，计算其所有样本的均值，将其作为新的聚类中心
4. 重复 2-3，直到聚类中心不再变化

用平方误差来衡量聚类效果

$$
\begin{aligned}
L &= \sum_{i=1}^{N} \sum_{k=1}^{K} r_{ik} d(x_i, \mu_k) \\
&= \sum_{i=1}^{N} \sum_{k=1}^{K} r_{ik} \|x_i - \mu_k\|_2^2
\end{aligned}
$$

其中 r_{ik} 为样本 x_i 属于第 k 个聚类的指示变量，即

$$
r_{ik} = \begin{cases} 1 & x_i \in C_k \\ 0 & x_i \notin C_k \end{cases}
$$

当簇具有不同的尺寸/密度/非球形时，K-Means 的效果不好

肘部法

肘部法用于确定聚类的数量，即 K 值，对于不同的 K 值，计算平方误差，然后绘制成折线图，找到拐点，即为最佳的 K 值

$$
K_\alpha = \min\{K | \frac{L_K - L_{K+1}}{\sigma^2} \leq \alpha\}
$$

假设检验法

假设检验法用于确定聚类的数量，即 K 值；假设理想簇分布服从多元正态分布，逐步增加 K 值，直至每个簇都服从多元正态分布

K-Means++

K-Means++ 用于初始化聚类中心，即第一步，K-Means++ 的思想是尽可能地让聚类中心之间的距离相互远离，具体步骤如下

1. 随机选择一个样本作为第一个聚类中心
2. 对于每个样本 x_i，计算其与已有聚类中心的距离 $d(x_i, C)$，其中 C 为已有聚类中心的集合
3. 选择一个样本作为新的聚类中心，其概率为 $\frac{d(x_i,C)^2}{\sum_{x_j \in X} d(x_j,C)^2}$

高斯混合模型

假定有 K 个潜在的服从高斯分布的簇，每个簇的概率为 π_k，每个簇的均值为 μ_k，每个簇的协方差矩阵为 Σ_k，则有

$$p(x) = \sum_{k=1}^{K} \pi_k \mathcal{N}(x; \mu_k, \Sigma_k) = \sum_{k=1}^{K} \pi_k \frac{1}{(2\pi)^{\frac{D}{2}} |\Sigma_k|^{\frac{1}{2}}} e^{-\frac{1}{2}(x-\mu_k)^T \Sigma_k^{-1} (x-\mu_k)}$$

损失函数为负对数似然函数，可以用 EM 算法求解；GMM 属于软分配，即概率分配，可以被用于椭球形簇的聚类，簇的概率可以不同

层次聚类

凝聚式/自底向上聚类：每个样本作为一个簇，然后逐步合并簇，直到满足停止条件，一般每次合并距离最近的两个簇

DBSCAN

基于密度的聚类算法，将高密度区域划分为簇，将低密度区域划分为噪声，具有噪声抗性，可以发现任意形状的簇，对参数敏感；基本概念如下

- ϵ-邻域：对于样本 x_i，其 ϵ-邻域为 $N_\epsilon(x_i) = \{x_j | d(x_i, x_j) \leq \epsilon\}$
- 核心点：对于样本 x_i，如果其 ϵ-邻域中的样本数量大于等于 $MinPts$，则称其为核心点
- 边界点：对于样本 x_i，如果其 ϵ-邻域中的样本数量小于 $MinPts$，但其 ϵ-邻域中存在核心点，则称其为边界点
- 噪声点：对于样本 x_i，如果其 ϵ-邻域中的样本数量小于 $MinPts$，且其 ϵ-邻域中不存在核心点，则称其为噪声点
- 密度可达：两个样本间存在由核心点构成的路径，使得路径上的每个样本都是对方的 ϵ-邻域中的样本，则称两个样本密度可达
- 密度相连：对于样本 x_i 和 x_j，如果存在样本 x_k，使得 x_i 和 x_j 都是 x_k 的 ϵ-邻域中的样本，则称 x_i 和 x_j 密度相连

DBSCAN 的基本思想是：从任意一个核心点开始，找到其密度可达的所有样本，将其划分为一个簇，然后继续寻找下一个未被访问的核心点，直到所有样本都被访问过；DBSCAN 的优点在于不需要指定簇的数量，可处理任意形状的簇，且对离群点较为鲁邦；缺点在于对参数敏感，对高维数据不适用，且计算复杂度较高

评价指标

Jaccard 系数

Rand 指数

轮廓系数

- a_i：样本 x_i 与同簇其他样本的平均距离
- $d_{i,k}$：样本 x_i 与其他簇 C_k 所有样本的平均距离
- $b_i = \min\limits_{k \neq i} d_{i,k}$：样本 x_i 与其他簇的平均距离的最小值
- $s_i = \frac{b_i - a_i}{\max\{a_i, b_i\}}$：样本 x_i 的轮廓系数
- 簇 C 的轮廓系数：$s = \frac{1}{|C|} \sum_{x_i \in C} s_i$

集成学习

Bagging

Bagging (Bootstrap Aggregating) 是一种基于自助采样法的集成学习算法，通过自助采样法从原始数据集中采样出 N 个样本，然后用这 N 个样本训练出 N 个模型，最后将这 N 个模型进行投票，得到最终的预测结果

$$f(x) = \frac{1}{N} \sum_{i=1}^{N} f_i(x)$$

Bagging 适合对偏差低、方差高的模型进行集成，如决策树、神经网络等；Bagging 可以并行训练；通常基学习器数量越多，集成效果越好，但是当基学习器数量达到一定程度时，集成效果不再提升，甚至会下降，这是因为基学习器之间的相关性增加

$$\mathbb{E}(f(x)) = \mathbb{E}\left(\frac{1}{N} \sum_{i=1}^{N} f_i(x)\right) = \frac{1}{N} \sum_{i=1}^{N} \mathbb{E}(f_i(x)) = \mathbb{E}(f_m(x))$$
$$\mathsf{Var}(f(x)) = \mathsf{Var}\left(\frac{1}{N} \sum_{i=1}^{N} f_i(x)\right) = \frac{1}{N^2} \sum_{i=1}^{N} \mathsf{Var}(f_i(x)) = \frac{1}{N} \mathsf{Var}(f_m(x))$$

随机森林

- 随机选择一部分样本
- 随机选择一部分特征

降低了树的相关性，也牺牲了可解释性

极度随机树

随机选取候选特征阈值，随机性更强；相较于随机森林，偏差更大，方差更小

Bootstrap

对于原始数据集 D，从中有放回地采样 N 个样本，得到采样集 D_i，则有

$$\begin{aligned}\mathbb{P}(x \in D_i) &= 1 - \mathbb{P}(x \notin D_i) \\ &= 1 - \left(1 - \frac{1}{N}\right)^N \\ &\approx 1 - e^{-1} \\ &\approx 0.632\end{aligned}$$

当 N 足够大时，样本 x 被采样到的概率为 0.632，未被采样到的概率为 0.368；未被采样到的数据称为包外 (out-of-bag) 数据，可以用于模型的验证，不需要额外的验证集

Boosting

顺序地训练多个弱学习器，每个弱学习器都在上一个弱学习器的基础上进行训练，最终将所有弱学习器进行加权求和，得到最终的预测结果

$$f(x) = \sum_{i=1}^{N} \alpha_i f_i(x)$$

Boosting 算法适用于高偏差、低方差的模型（性能弱，深度浅），可以降低偏差，不能并行训练

AdaBoost

对训练集中的每个样本赋予一个权重 w_i，初始时；每次训练出一个弱学习器后，更新样本的权重，使得误分类样本的权重增大，正确分类样本的权重减小，并且下一轮的误分类样本权重之和总等于 0.5，即满足随机猜想的条件。

每轮训练时的加权误识率为

$$\epsilon_i = \sum_{x_j \in D_i} w_j^{(i)} \mathbb{I}(y_j \neq f_i(x_j))$$

新一轮的样本权重中，放大了误分类样本的权重，缩小了正确分类样本的权重

$$w_j^{(i+1)} = \begin{cases} \dfrac{w_j^{(i)} d_i^{-1}}{z_i} & y_j = f_i(x_j) \\ \dfrac{w_j^{(i)} d_i}{z_i} & y_j \neq f_i(x_j) \end{cases}$$

其中 z_i 为归一化因子，是为了保证下一轮的权重之和为 1，仍然是一个分布

$$\begin{aligned} z_i &= \sum_{x_j \in D_i} d_i w_j^{(i)} \mathbb{I}(y_j \neq f_i(x_j)) + \sum_{x_j \in D_i} d_i^{-1} w_j^{(i)} \mathbb{I}(y_j = f_i(x_j)) \\ &= d_i \sum_{x_j \in D_i} w_j^{(i)} \mathbb{I}(y_j \neq f_i(x_j)) + d_i^{-1} \sum_{x_j \in D_i} w_j^{(i)} \mathbb{I}(y_j = f_i(x_j)) \\ &= d_i \epsilon_i + d_i^{-1}(1 - \epsilon_i) \end{aligned}$$

每轮训练后，更新样本权重，且满足下一轮的误分类样本权重之和总等于 0.5

$$\begin{aligned} d_i \epsilon_i &= d_i^{-1}(1 - \epsilon_i) \\ d_i &= \sqrt{\frac{1 - \epsilon_i}{\epsilon_i}} \\ z_i &= d_i \epsilon_i + d_i^{-1}(1 - \epsilon_i) = 2\sqrt{\epsilon_i(1 - \epsilon_i)} \end{aligned}$$

对应学习器的权重为

$$\alpha_i = \ln d_i = \frac{1}{2} \ln \frac{1 - \epsilon_i}{\epsilon_i}$$

d_i 可以重写为 $\exp(\alpha_i)$，假定二分类标签 $y_i \in \{-1, 1\}$，则有指示变量 $y_i f_i(x_i)$，当 $y_i = f_i(x_i)$ 时，指示变量为 1，当 $y_i \neq f_i(x_i)$ 时，指示变量为 -1，

$$w_j^{(i+1)} = \frac{w_j^{(i)} \exp(-\alpha_i y_i f_i(x_i))}{z_i}$$

Gradient Boosting

梯度提升算法采用了梯度更新的思想，每次迭代时都在上一轮的梯度方向上进行优化，即

$$f_{m+1}(x) = f_m(x) - \eta \frac{\partial L}{\partial f}(y, f_m(x))$$

对于回归问题，可以采用 L2 损失函数，称为 L2Boosting

$$\begin{aligned}
L(y, f(x)) &= \frac{1}{2}(y - f(x))^2 \\
\frac{\partial L}{\partial f}(y, f(x)) &= f(x) - y \\
f_{m+1}(x) &= f_m(x) - \eta(f_m(x) - y) \\
&= (1-\eta) f_m(x) + \eta y
\end{aligned}$$

对于分类问题，可以采用交叉熵损失函数，称为 LogitBoosting

$$\begin{aligned}
p_k &= \frac{e^{f_k(x)}}{\sum_{i=1}^K e^{f_i(x)}} \\
L(y, f(x)) &= -\sum_{k=1}^K y_k \ln p_k \\
&= -\sum_{k=1}^K y_k \ln \frac{e^{f_k(x)}}{\sum_{i=1}^K e^{f_i(x)}} \\
&= -\sum_{k=1}^K y_k f_k(x) + \sum_{k=1}^K y_k \ln \sum_{i=1}^K e^{f_i(x)} \\
\frac{\partial L}{\partial f_m}(y, f(x)) &= -y_m + \sum_{k=1}^K y_k \frac{e^{f_k(x)}}{\sum_{i=1}^K e^{f_i(x)}} \\
&= -y_m + \sum_{k=1}^K y_k p_k \\
&= p_m - y_m
\end{aligned}$$